

曲线拟合

导入基础包:

```
In [1]: import numpy as np
import matplotlib as mpl
import matplotlib.pyplot as plt
```

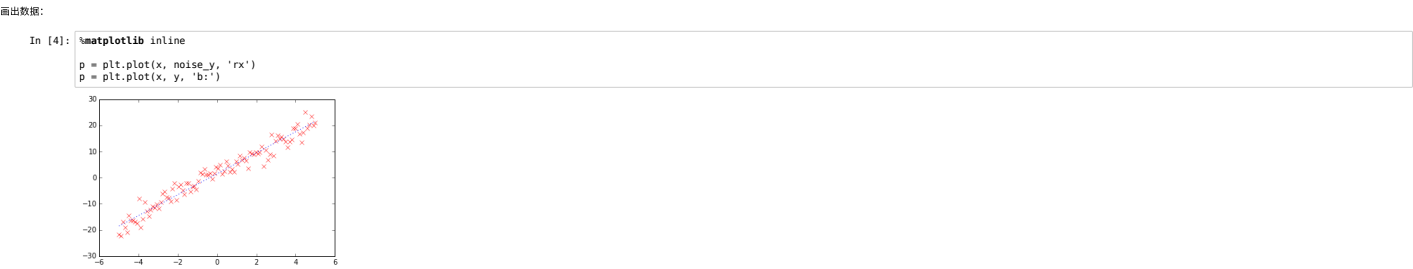
多项式拟合

导入线多项式拟合工具:

```
In [2]: from numpy import polyfit, poly1d
```

产生数据:



```
In [3]: x = np.linspace(-5, 5, 100)
y = 4 * x + 1.5
noise_y = y + np.random.randn(y.shape[-1]) * 2.5
```



进行线性拟合, polyfit 是多项式拟合函数, 线性拟合即一阶多项式:

```
In [5]: coeff = polyfit(x, noise_y, 1)
print coeff
[ 3.93921315  1.59379469]
```

一阶多项式 $y = a_1x + a_0$ 拟合, 返回两个系数 $[a_1, a_0]$ 。



```
In [8]: f
Out[8]: poly1d([ 3.93921315,  1.59379469])
```

显示 f:

```
In [9]: print f
3.939 x + 1.594
```

还可以对它进行数学操作生成新的多项式:

```
In [10]: print f + 2 * f ** 2
31.83 x + 29.85 x + 6.674
```

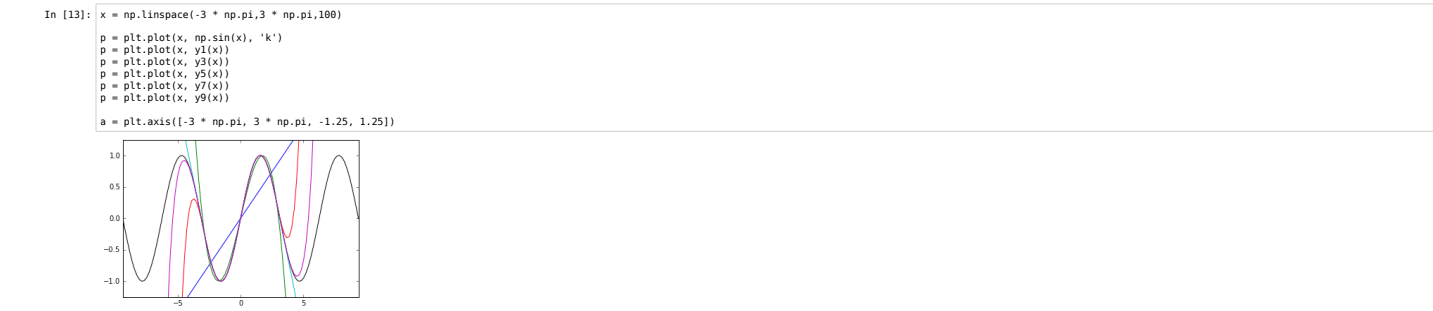
多项式拟合正弦函数

正弦函数:

```
In [11]: x = np.linspace(-np.pi, np.pi, 100)
y = np.sin(x)
```

用一阶到九阶多项式拟合, 类似泰勒展开:

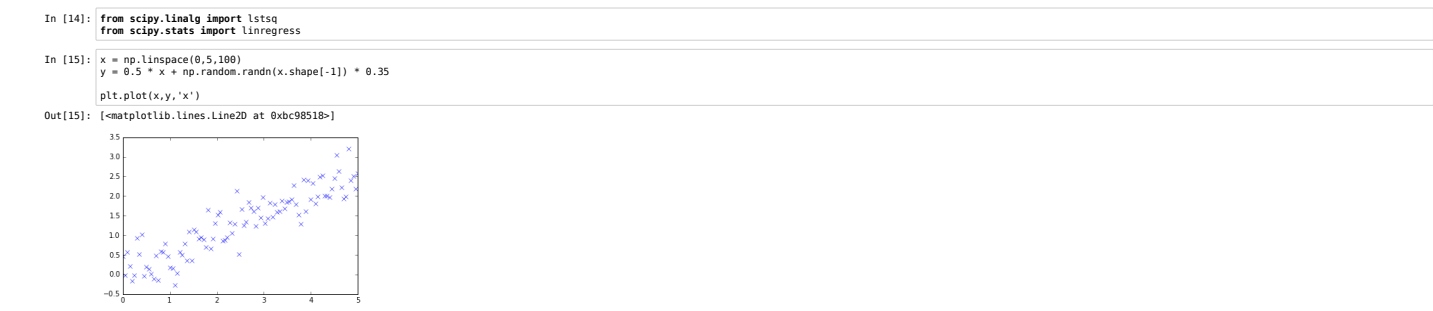
```
In [12]: y1 = poly1d(polyfit(x, y, 1))
y3 = poly1d(polyfit(x, y, 3))
y5 = poly1d(polyfit(x, y, 5))
y7 = poly1d(polyfit(x, y, 7))
y9 = poly1d(polyfit(x, y, 9))
```



黑色为原始的图形，可以看到，随着多项式拟合的阶数的增加，曲线与拟合数据的吻合程度在逐渐增大。

最小二乘拟合

导入相关的模块：



一般来书，当我们使用一个 N-1 阶的多项式拟合这 M 个点时，有这样的关系存在：

即


$$XC = Y$$

$$\begin{bmatrix} x_0^{N-1} & \cdots & x_0 & 1 \\ x_1^{N-1} & \cdots & x_1 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ x_M^{N-1} & \cdots & x_M & 1 \end{bmatrix} \begin{bmatrix} C_{N-1} \\ \vdots \\ C_1 \\ C_0 \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_M \end{bmatrix}$$


Scipy.linalg.lstsq 最小二乘解

要得到 C，可以使用 scipy.linalg.lstsq 求最小二乘解。

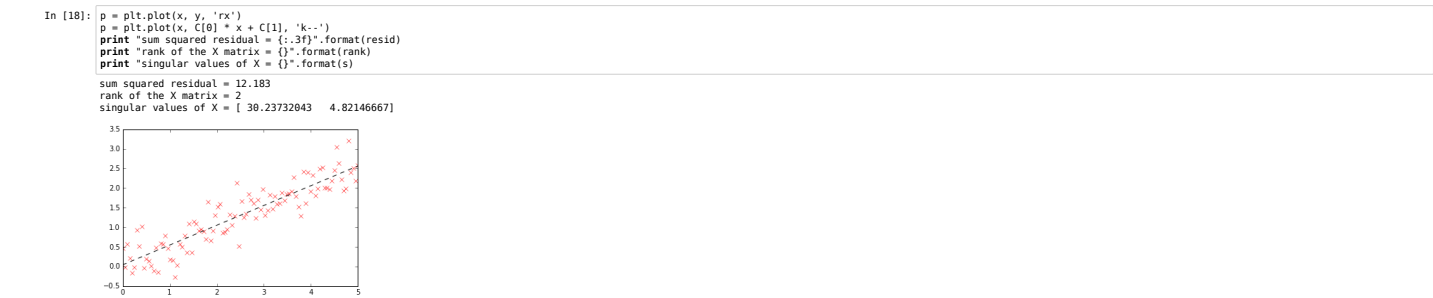
这里，我们使用 1 阶多项式即 N = 2，先将 x 扩展成 X：



求解：

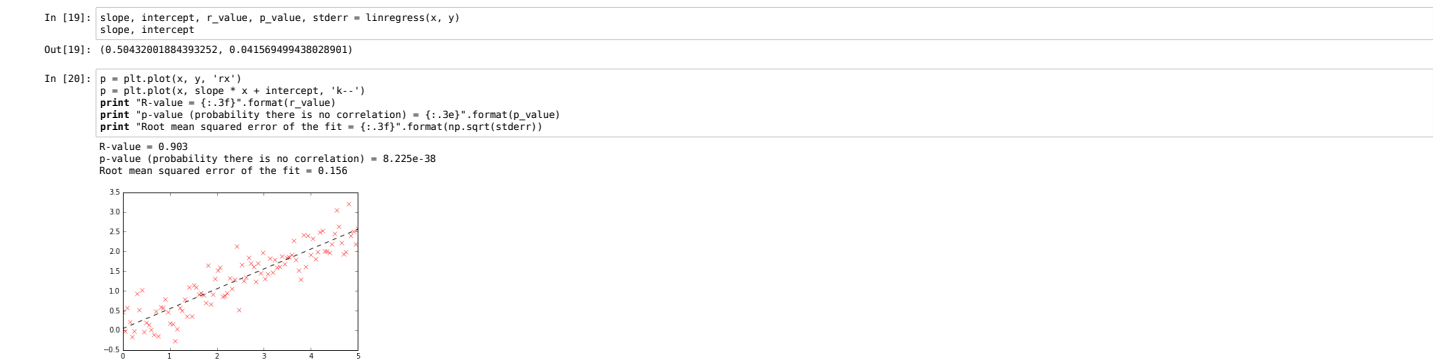


画图：



Scipy.stats.linregress 线性回归

对于上面的问题，还可以使用线性回归进行求解：



可以看到，两者求解的结果是一致的，但是出发的角度是不同的。

更高级的拟合


```
In [21]: from scipy.optimize import leastsq
```

先定义这个非线性函数: $y = ae^{-b \sin(fx+\phi)}$

```
In [22]: def function(x, a, b, f, phi):
        """a function of x with four parameters"""
        result = a * np.exp(-b * np.sin(f * x + phi))
        return result
```


画出原始曲线:

```
In [23]: x = np.linspace(0, 2 * np.pi, 50)
        actual_parameters = [3, 2, 1.25, np.pi / 4]
        y = function(x, *actual_parameters)
        p = plt.plot(x, y)
```



加入噪声:

```
In [24]: from scipy.stats import norm
        y_noisy = y + 0.8 * norm.rvs(size=len(x))
        p = plt.plot(x, y, 'k-')
        p = plt.plot(x, y_noisy, 'rx')
```



Scipy.optimize.leastsq

定义误差函数，将要优化的参数放在前面:


```
In [25]: def f_err(p, y, x):
        return y - function(x, *p)
```

将这个函数作为参数传入 leastsq 函数，第二个参数为初始值:

```
In [26]: c, ret_val = leastsq(f_err, [1, 1, 1, 1], args=(y_noisy, x))
        c, ret_val
Out[26]: (array([ 3.03199715,  1.97689384,  1.30883191,  0.6393337 ]), 1)
```

ret_val 是 1-4 时，表示成功找到最小二乘解:

```
In [27]: p = plt.plot(x, y_noisy, 'rx')
        p = plt.plot(x, function(x, *c), 'k--')
```



Scipy.optimize.curve_fit


更高级的做法:

```
In [28]: from scipy.optimize import curve_fit
```

不需要定义误差函数，直接传入 function 作为参数:

```
In [29]: p_est, err_est = curve_fit(function, x, y_noisy)
```

```
In [30]: print p_est
        p = plt.plot(x, y_noisy, "rx")
        p = plt.plot(x, function(x, *p_est), "k--")
        [ 3.03199711  1.97689385  1.3088319  0.63933373]
```



这里第一个返回的是函数的参数，第二个返回值为各个参数的协方差矩阵:

```
In [31]: print err_est
[[ 0.08483704 -0.02782318  0.00967093 -0.03029038]
 [-0.02782318  0.00933216 -0.00305158  0.00955794]
 [ 0.00967093 -0.00305158  0.0014972  -0.00468919]
 [-0.03029038  0.00955794 -0.00468919  0.01404297]]
```

协方差矩阵的对角线为各个参数的方差:

```
In [32]: print "normalized relative errors for each parameter"
        print "a\t b\t f\t phi"
        print np.sqrt(err_est.diagonal()) / p_est
        normalized relative errors for each parameter
        a\t b\t f\t phi
        [ 0.09606473  0.0488661  0.02974528  0.19056043]
```